Análisis de estimadores puntuales usando simulación en R

Joaquín Álvarez Galnares

24 de diciembre de 2021

Abstract

Revisamos un ejemplo de estimadores puntuales para el caso de la distibución exponencial. El objetivo es complementar argumentos teóricos y analíticos con ideas visuales para tener más claridad mental. Esto está motivado por tareas del Prof. L.E. Nieto Barajas. Cualquier error es de mi autoría.

Contexto

Sea $X_1, ..., X_n$ una muestra aleatoria de la población $f(x|\theta) = \theta e^{-\theta x} \mathbb{1}^{(x)}_{(0,\infty)}$, $\theta \in \Theta := (0, \infty)$. Sean $\tau_1(\theta) = \theta, \tau_2(\theta) = F(x|\theta) = \mathbb{P}\{X \leq x \ |\theta\} = 1 - e^{-\theta x}$, para $x \in (0, \infty)$ fija.

Consideremos los siguientes estimadores de τ_1 construídos con el método de momentos:

$$\tilde{\tau}_{11} := \frac{1}{\bar{X}}, \text{ donde } \bar{X} := \frac{1}{n} \sum_{i=1}^{n} X_i \text{ denota a la media muestral}$$

$$\tilde{\tau}_{12} := \sqrt{\frac{2}{\frac{1}{n} \sum_{i=1}^{n} X_i^2}}$$

Y consideremos los siguientes estimadores puntuales de τ_2:

$$\tilde{\tau}_{21} := 1 - exp\{-\frac{x}{\bar{X}}\}$$

$$\tilde{\tau}_{22} := \frac{1}{n} \sum_{k=1}^{n} \mathbb{1}_{(-\infty,x]}(X_k), \text{ donde}$$

$$\mathbb{1}_{(-\infty,x]}(X_k) := \begin{cases} 1 & \text{si } X_k \leq x \\ 0, & \text{en otro caso} \end{cases} \quad , \forall k \in \{1, 2, \ldots, n\}$$

Tomemos $\theta = 3$. Queremos estudiar propiedades de estos estimadores (tales como su varianza, insesgamiento y consistencia) apoyándonos en R.

Observaciones preliminares acerca de algunas propiedades de estos estimadores

Notemos que $\tilde{\tau}_{11}$ es un estimador suficiente para θ pues es función de la media muestral, la cual es estadística suficiente para θ, por lo que esperamos que sea 'mejor' que $\tilde{\tau}_{12}$, pues $\tilde{\tau}_{12}$ es un estimador que no es función de una estadística suficiente para θ.

Afirmación: $\tilde{\tau}_{11}$ es estimador asintóticamente insesgado de τ_1.

Dem

Nótese que

$$Y := \sum_{i=1}^{n} X_i \sim Gamma(r = n, \lambda = \theta)$$

Además podemos escribir a $\tilde{\tau}_{11}$ como función de Y:

$$\tilde{\tau}_{11} = \frac{n}{Y}$$

Entonces, usando la Ley del Estadístico Inconsciente y completando la densidad de otra $Gamma(n-1, \theta)$, resulta que

$$\begin{aligned}
\mathbb{E}[\tilde{\tau}_{11}] = \mathbb{E}\left[\frac{n}{Y}\right] &= n \int_0^\infty \frac{1}{y} \frac{\lambda^r}{\Gamma(r)} y^{r-1} e^{-\lambda y} dy \\
&= n \frac{\lambda^r}{\Gamma(r)} \int_0^\infty y^{r-1-1} e^{-\lambda y} dy \\
&= n \frac{\lambda^r}{\Gamma(r)} \frac{\Gamma(r-1)}{\lambda^{r-1}} \underbrace{\int_0^\infty \frac{\lambda^{r-1}}{\Gamma(r-1)} y^{r-1-1} e^{-\lambda y} dy}_{=1} \\
&= n \frac{\lambda^r}{\Gamma(r)} \frac{\Gamma(r-1)}{\lambda^{r-1}} = n \frac{\lambda (r-2)!}{(r-1)!} = \frac{n\lambda}{r-1}
\end{aligned}$$

Y como $r = n$ y $\lambda = \theta$,

$$\mathbb{E}[\tilde{\tau}_{11}] = \frac{n}{n-1}\theta \xrightarrow{n \to \infty} \theta$$

■

Más aún, $\mathbb{E}[\tilde{\tau}_{11}] = \frac{n}{n-1}\theta > \theta$, por lo que, en promedio, el estimador $\tilde{\tau}_{11}$ sobreestima el valor de θ. Intuitivamente, esto debe traducirse a una distribución de muestreo sesgada a la derecha de $\theta = 3$. Vamos a confirmar esta observación visualmente con un plot en R.

Afirmación: La función de distribución empírica $\tilde{\tau}_{22}$ es una estadística, que como variable aleatoria es discreta, y es un estimador insesgado de $\tau_2(\theta)$.

Dem

Para manejar una notación más sencilla, para cada $k \in \{1, 2, \ldots, n\}$ sea

$$I_k := \mathbb{1}_{(-\infty, x]}(X_k) \sim \mathcal{B}ernoulli(\tau_2)$$

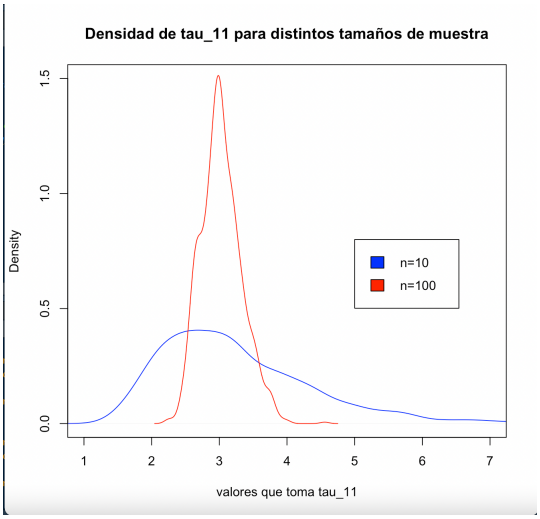
Así

$$\tilde{\tau}_{22} = \frac{1}{n}\sum_{k=1}^{n} I_k$$

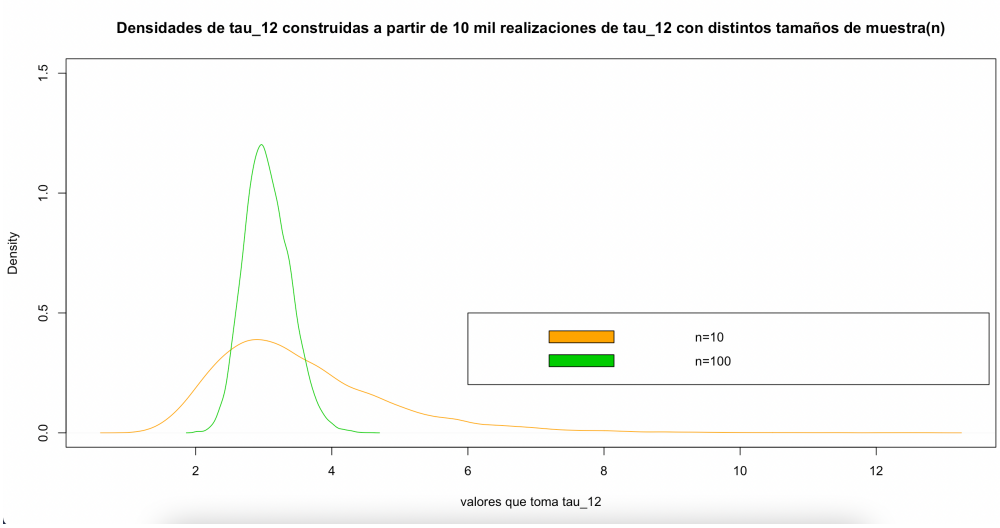
Como $\sum_{k=1}^{n} I_k \sim \mathcal{B}inomial(n, \tau_2)$ y la distribución binomial es v.a. discreta, entonces $\tilde{\tau}_{22}$ es v.a. discreta. Más aún, $\mathbb{E}[\sum_{k=1}^{n} I_k] = n\tau_2$, por lo que $\mathbb{E}[\tilde{\tau}_{22}] = \tau_2$.

■

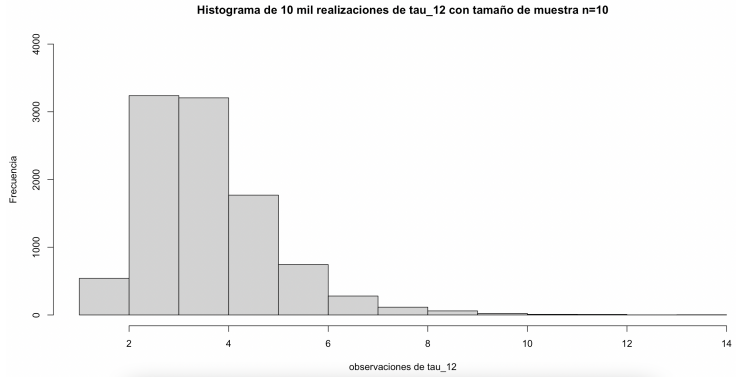
Simulaciones en R



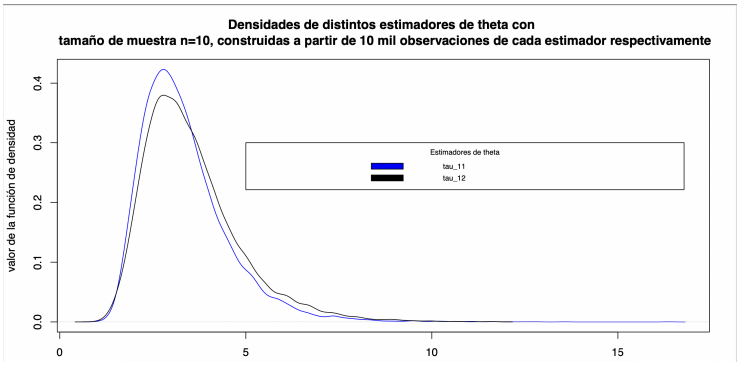
Notamos que efectivamente la distribución de muestreo de $\tilde{\tau}_{11}$ tiene un sesgo a la derecha, lo cual confirma la observación que hicimos en la sección anterior respecto al sesgo de $\tilde{\tau}_{11}$. Al incrementar el tamaño de n, se acumula más probabilidad en una vecindad de $\theta = 3$, por lo que $\tilde{\tau}_{11}$ es consistente.



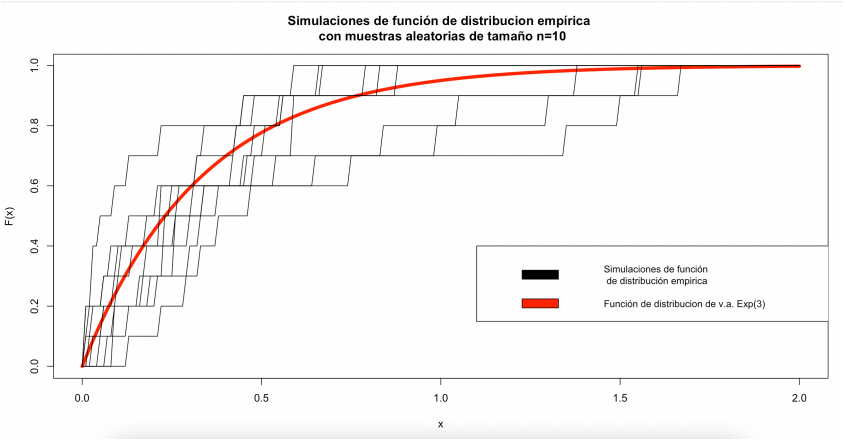
Podemos notar que la distribución de $\tilde{\tau}_{12}$ tiene propiedades similares a la de $\tilde{\tau}_{11}$



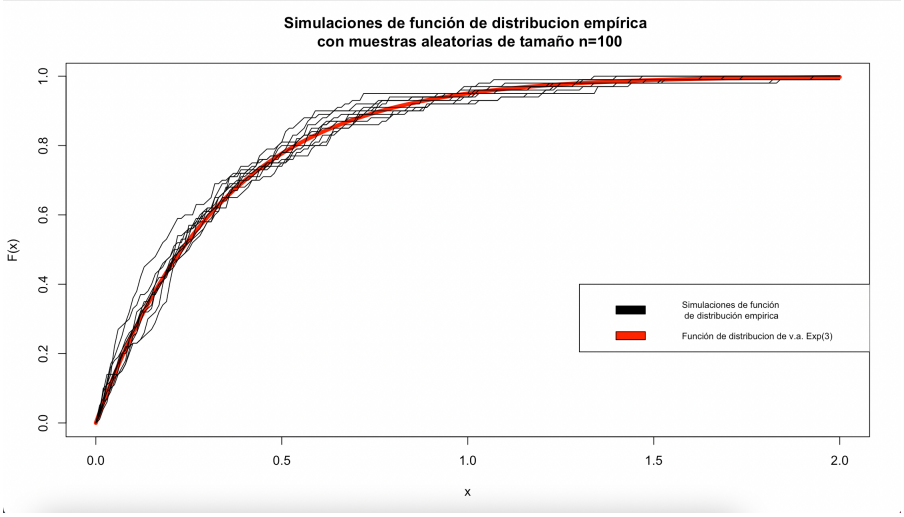
Podemos apreciar el sesgo de $\tilde{\tau}_{12}$ a la derecha, por lo que $\tilde{\tau}_{12}$ tiende a sobreestimar el valor de θ.



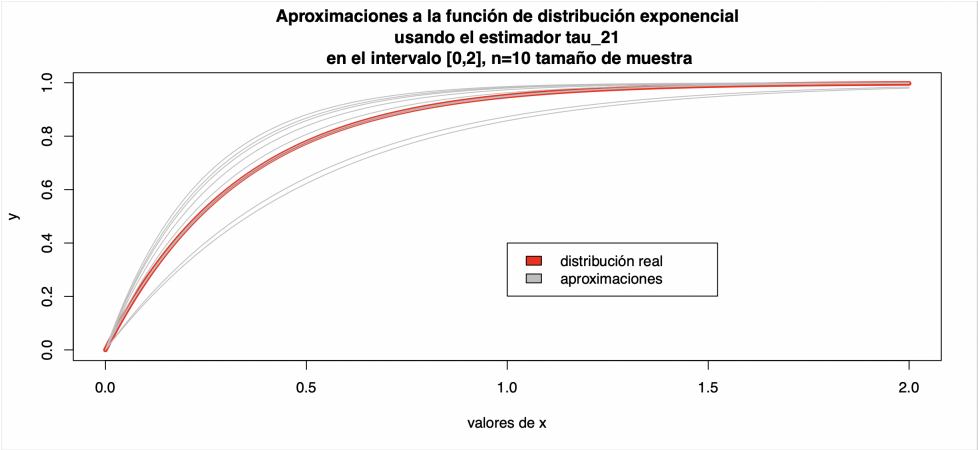
Este plot nos permite hacer una comparación más clara entre $\tilde{\tau}_{11}$ y $\tilde{\tau}_{12}$. Podemos destacar que $\tilde{\tau}_{11}$ tiene una densidad (línea azul) con cola menos pesada hacia la derecha (lo cual confirma visualmente que tiene menor varianza que $\tilde{\tau}_{12}$) y además acumula más probabilidad alrededor de $\theta = 3$, lo cual confirma que es mejor estimador respecto a estos criterios. Más aún, promediando 10 mil realizaciones de ambos estimadores con tamaño de muestra n=10 obtuvimos que $\tilde{\tau}_{11}$ tuvo una media más cercana a 3 que $\tilde{\tau}_{12}$, por lo que concluímos que es preferible el estimador $\tilde{\tau}_{11}$.

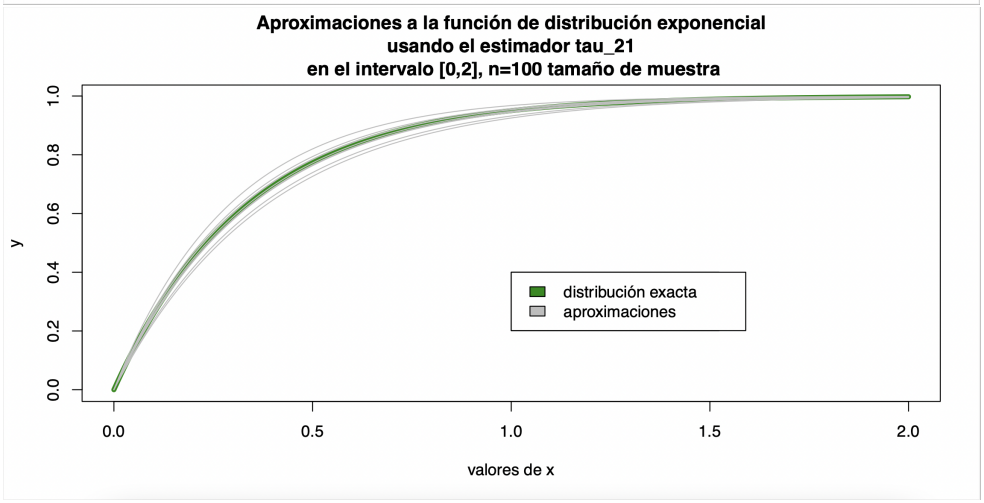


Aquí podemos notar que la función de distribución empírica efectívamente es discreta como función de x.



Al incrementar el valor de n la distribución empírica converge a la funcion de distribución, y comienza a tener un aspecto más contínuo como función de x. Si formamos una vecindad tubular alrededor de la línea roja notamos que cada vez se van quedando más dentro de esa vecindad tubular las realizaciones de la función de distribución empírica. En otras palabras, al incrementar el tamaño de muestra, la aproximación que nos da la función de distribución empírica mejora.





Las gráficas muestran 10 simulaciones del estimador $\tilde{\tau}_{21}$ variando x en [0,2]. Este estimador, a diferencia de la distribución empírcia, como variable alearia es contínua, pues es función inyectiva de la media muestral, la cual es variable aleatoria contínua. Notamos que al incrementar el tamaño de muestra las simulaciones producen mejores estimadores, en el sentido de que quedan más cercanos al valor de la función de distribución, para cada $x \in [0, 2]$.