Intervalos de Confianza

Joaquín Álvarez Galnares

27 de diciembre de 2021

Abstract

Analizamos intervalos de confianza en R con un ejemplo. El código usado está incluido al final del archivo. El objetivo es complementar argumentos teóricos y analíticos con ideas visuales para tener más claridad mental. Esto está motivado por tareas del Prof. L.E. Nieto Barajas. Cualquier error es de mi autoría.

Planteamiento del problema

Sea $X_1, X_2, \ldots, X_n$ una muestra aleatoria de una población $\mathcal{N}(\mu, \sigma^2)$ con σ^2 conocida. Nuestro objetivo es estudiar propiedades de intervalos de confianza de μ constuídos usando el método pivotal.

Construcción de cantidades pivotales

Recordemos el método de la transformada inversa:

Si X es una variable aleatoria contínua con función de distribución F, entonces

$$F(X) \sim U(0,1)$$

Es sencillo verificar que si $U \sim U(0,1)$, entonces $-log(U) \sim Exp(1)$. A partir de estas observaciones y usando el hecho de que $X_1, X_2, \ldots, X_n$ son v.a.i.i.d., resulta que

$$Q_1 \coloneqq \sum_{i=1}^{n} -2log\big(F(X_i|\mu)\big) \sim \chi^2_{(2n)}$$

es cantidad pivotal ya que $Q_1 = Q_1(\underline{X}, \mu)$ es función de μ y su distribución no depende de parámetros desconocidos. Si estandarizamos, podemos escribir a Q_1 en términos de la función de distribución de una normal estándar, Φ, y obtenemos que

$$Q_1 = \sum_{i=1}^{n} -2log\Big(\Phi\Big(\frac{X_i - \mu}{\sigma}\Big)\Big)$$

Por otro lado, como $\bar{X} \sim \mathcal{N}(\mu, \frac{\sigma^2}{n})$, entonces

$$Q_2 \coloneqq \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0,1)$$

también es una cantidad pivotal, ya que $Q_2(\underline{X}, \mu)$ tiene una distribución que no depende de parámetros desconocidos.

Sea $\alpha \in (0,1)$. Queremos construir un intervalo de confianza a partir de Q_1 y de Q_2 al $(1-\alpha)100\%$ de confianza.

Notamos que si tratamos de aplicar el método pivotal usando Q_1, no es posible despejar analíticamente a μ partiendo de:

$$1-\alpha = \mathbb{P}\left\{\chi^2_{(2n),1-\frac{\alpha}{2}} \leq \sum_{i=1}^{n} -2log\Big(\Phi\Big(\frac{X_i-\mu}{\sigma}\Big)\Big) \leq \chi^2_{(2n),\frac{\alpha}{2}}\right\}$$

Es decir, no es posible 'pivotear' analíticamente. Sin embargo, sí podemos pivotear numéricamente. La estrategia consiste en explorar en una vecindad alrededor de μ. Digamos que $\underline{X} = \underline{x}$ es una observación de la muestra aleatoria. A partir de esta realización podemos obtener una realización del intervalo de confianza para μ a partir de Q_1. Pero ¿cómo proponer una vecindad de μ si no sabemos cuánto vale y ese es justo el problema que queremos resolver? La idea es dar una vecindad muy cruda que nos sirva para tener una región en dónde explorar y refinarla. Podemos definir una vecindad alrededor de μ con la siguiente idea. Como $\bar{X}$ es un estimador puntual de μ y σ^2 es conocida, podemos tomar $I \coloneqq [\bar{x} - 5\sigma/\sqrt{n}, \bar{x} + 5\sigma/\sqrt{n}]$ como vecindad de μ. La idea detrás de esta propuesta como vecindad es que $\bar{X} \sim \mathcal{N}(\mu, \sigma^2/n)$, por lo cual es altamente probable que $\mu \in I$. Podemos usar incluso más de 5 desviaciones estándar para tener mayor margen de error, sin embargo eso tiene un costo computacional pues la región de búsqueda se hace más grande; la idea es que dejamos un margen de error alto para poder constuir un intervalo de confianza (denotémoslo por $I_c \subset I$) para μ a partir de I de acuerdo con el siguiente criterio:

$$\tilde{\mu} \in I_c \iff \chi^2_{(2n),1-\frac{\alpha}{2}} \leq \sum_{i=1}^{n} -2log\Big(\Phi\big(\frac{x_i-\tilde{\mu}}{\sigma}\big)\Big) \leq \chi^2_{(2n),\frac{\alpha}{2}}$$

Para Q_2 sí es posible pivotear analíticamente:

$$1-\alpha = \mathbb{P}\Big(-z_{\frac{\alpha}{2}} \leq \frac{\bar{X}-\mu}{\sigma/\sqrt{n}} \leq z_{\frac{\alpha}{2}}\Big) = \mathbb{P}\Big(\bar{X} - z_{\frac{\alpha}{2}}\frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + z_{\frac{\alpha}{2}}\frac{\sigma}{\sqrt{n}}\Big)$$

Por lo que $\mu \in \big(\bar{x} - z_{\frac{\alpha}{2}}\frac{\sigma}{\sqrt{n}}, \bar{x} + z_{\frac{\alpha}{2}}\frac{\sigma}{\sqrt{n}}\big)$ con $(1-\alpha)100\%$ de confianza.

Observación: La longitud de este intervalo de confianza es $2z_{\frac{\alpha}{2}}\frac{\sigma}{\sqrt{n}}$ por lo que no depende de la realización de la muestra aleatoria.

Pseudocódigo para obtener un intervalo de confianza basado en Q_1

Algorithm Construcción numérica de un intervalo de confianza usando la cantidad pivotal Q_1

procedure NUMERIC(n,α, I)

n: el tamaño de muestra

$1-\alpha$: el coeficiente de confianza

I: es una partición de la vecindad de μ en la cual exploramos

$I_c \leftarrow \emptyset$ ▷ valores de $\tilde{\mu}$ que están en el intervalo de confianza

generar muestra aleatoria $\mathbf{X} \sim \mathcal{N}(\mu, \sigma^2)$

$q_1 \leftarrow \chi^2_{(2n),1-\frac{\alpha}{2}}$

$q_2 \leftarrow \chi^2_{(2n),\frac{\alpha}{2}}$

for $\tilde{\mu} \in I$ **do**

$r \leftarrow \sum_{i=1}^{n} -2log\big(\Phi(\frac{x_i-\tilde{\mu}}{\sigma})\big)$

if $q_1 \leq r \leq q_2$ **then**

$\tilde{\mu} \in I_c$

end if

end for

$m_1 \leftarrow min(I_c)$

$m_2 \leftarrow max(I_c)$

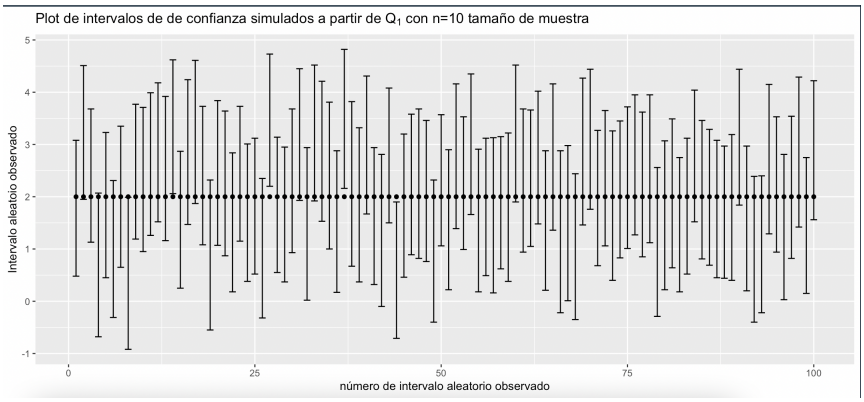
$I_c \leftarrow [m_1, m_2]$

return I_c ▷ realización del intervalo aleatorio

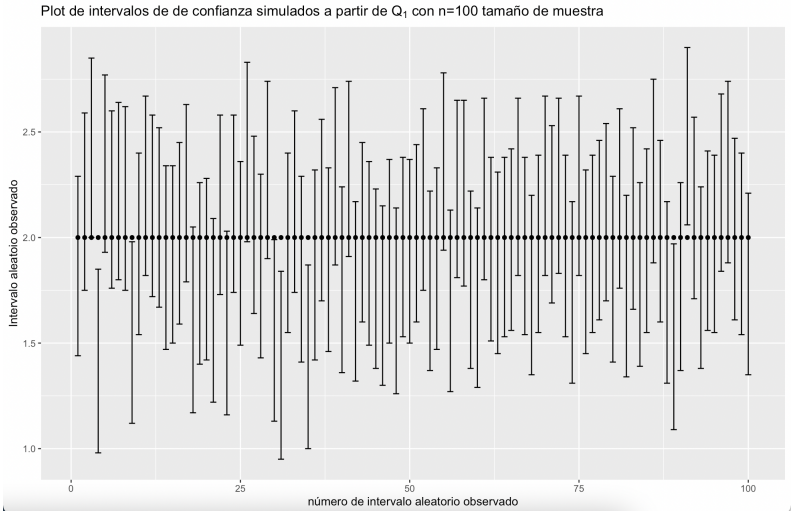
Análisis con un ejemplo

Tomando $\mu = 2, \sigma^2 = 4, \alpha = 0.05$ constuímos algunos intervalos de confianza basándonos en las ideas presentadas en la sección anterior.

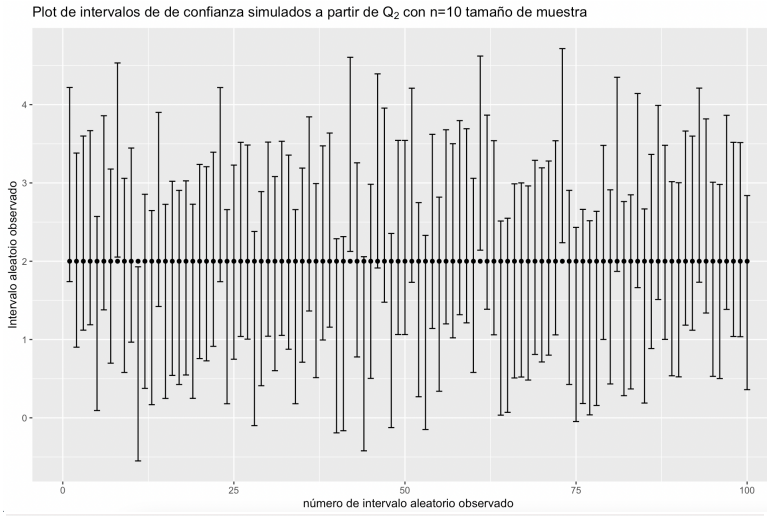
Observación importante: Incrementar el tamaño de muestra no implica incrementar la probabilidad de que el intervalo de confianza incluya al parámetro que queremos estimar. Solamente reduce la longitud del intervalo, haciendo que, para una misma probabilidad de que se incluya al parámetro en el intervalo, tengamos más precisión.

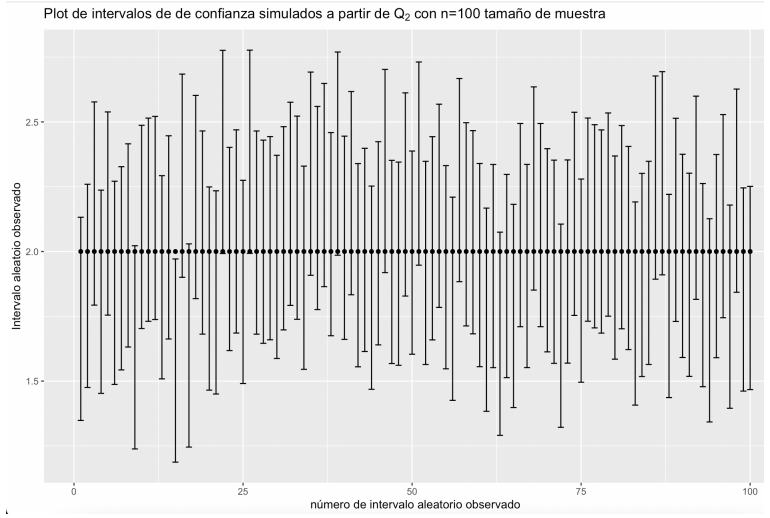


Podemos notar que, por ejemplo, la realización #27 no contiene al parámetro $\mu = 2$. Como es de esperarse, la gran mayoría de los intervalos sí contienen al parámetro que se desea estimar, por lo que los intervalos de confianza obtenidos numéricamente a partir de la cantidad pivotal Q_1 efectivamente cumplen con su función de darnos una región en la cual vive μ con cierto nivel de confianza



A pesar de que ahora n es más grande, no debería de sorprendernos que también obtengamos realizaciones de intervalos aleatorios que no incluyen a $\mu = 2$ pues la probabilidad de que eso ocurra no ha cambiado. Lo que es más destacable es el cambio en la escala en el eje y, lo cual refleja que la longitud de estos intervalos es menor en comparación a los intervalos construídos con n=10.





Se observa el mismo fenómeno que en los intervalos usando Q_1: al incrementar el tamaño de muestra, disminuye la longitud de los intervalos.

Si comparamos los 100 intervalos de confianza simulados a partir de Q_1 con aquellos generados a partir de Q_2 para un mismo tamaño de muestra, tenemos:

Cantidad pivotal	Tamaño de muestra	Longitud promedio de intervalos de confianza
Q_1	10	2.7254
Q_2	10	2.4791
Q_1	100	0.8576
Q_2	100	0.7839

Para ambos tamaños de muestra obtuvimos que la longitud promedio de los

intervalos generados a partir de Q_1 es mayor a la longitud promedio de los intervalos generados con Q_2. Por lo tanto, es preferible usar Q_2, pues para un mismo nivel de confianza y un mismo tamaño de muestra nos da intervalos de confianza con menos longitud y por lo tanto con mayor precisión. Una posible explicación de por qué obtuvimos estos resultados es que Q_1 no se basa en una estadística suficiente para μ, mientras que Q_2 se basa en la media muestral, la cual es una estadística suficiente para μ.

Código en R

```
# construcción de intervalos de confianza
getwd()
#paquetes que vamos a usar
#para simbolos fancy
install.packages("latex2exp")
library(latex2exp)
install.packages('ggplot2') #instalamos ggplot2
library('ggplot2') #cargamos ggplot2
install.packages('plotrix')
library("plotrix")
inter=seq(-1,5,1/100) #intervalo donde vamos a explorar
print(inter)
l=length(inter)
n=10
q1=qchisq(p=0.05/2, df=2*n) #q1 es t.q. se acumula .025 de prob a la izquierda y 0.975
#a la derecha
q1
q2=qchisq(p=0.975, df=2*n)
q2
#vamos a simular 100 realizaciones de  intervalos aleatorios para cada tamaño de muestra
#y para cada cantidad pivotal
cotaInf1=1:100 #aqui guardamos las cotas inferiores de cada intervalo aleatorio
cotaSup1=1:100 #aqui guardamos las cotas superiores de cada intervalo aleatorio
for(k in 1:100){
  simulado=rnorm(n,mean=2,sd=2) #generamos muestra de tamano n para constuir el IC
  indica=1:l #vector auxiliar para construir el IC. Nos va a decir que valores de
  #mu tomar para construir el IC
  #quiero que quede lleno de ceros
  for (j in 1:l){
    indica[j]=0
  }
  for(m in 1:l){#agarramos una mu y nos preguntamos si vive o no en el
    #intervalo de confianza
    Q<-0
    for(i in 1:n){
```

```
      Q=Q-2*log(pnorm((simulado[i]-inter[m])/2))
    }
    #print(Q)
    if((q1<Q) && (Q<q2)){
      indica[m]=1 #quiere decir que la m sí vive en el intervalo aleatorio
    }
    else{
      indica[m]=0 #entonces la m no esta en el intervalo de confianza
    }
  }
  u=which(indica==1) #nos ayuda a identificar que valores de m viven en el
  #intervalo aleatorio
  cotaInf1[k]=inter[min(u)]
  cotaSup1[k]=inter[max(u)]
}
cotaInf1
cotaSup1
print(cotaInf1[2])
print(cotaSup1[2])
#esto nos ayuda a leer la realizacion del segundo intervalo aleatorio simulado.
#
#check de que tiene sentido
for (i in 1:100){
  if(cotaInf1[i]<cotaSup1[i]){
    print(1)
  }
  else{
    print(0)
  }
}
#escupe puros unos :)
#tambien podemos  contar cuantos intervalos de los 100 incluyen al valor de mu=2
cuentas=0
for(j in 1:100){
  if(cotaInf1[j]<2 && 2<cotaSup1[j]){
    cuentas<-cuentas+1
  }
}
print(cuentas)
#
#ahora vamos con muestras de tama;o n=100
n=100
q1=qchisq(p=0.05/2, df=2*n) #q1 es t.q. se acumula .025 de prob a la izquierda y
#0.975 a la derecha
q1
q2=qchisq(p=0.975, df=2*n)
```

```
q2
#vamos a simular 100 realizaciones de  intervalos aleatorios para cada tamaño de
#muestra y para cada cantidad pivotal
cotaInf=1:100 #aqui guardamos las cotas inferiores de cada intervalo aleatorio
cotaSup=1:100 #aqui guardamos las cotas superiores de cada intervalo aleatorio
for(k in 1:100){
  simulado=rnorm(n,mean=2,sd=2) #generamos muestra de tamano n para constuir el IC
  indica=1:l #vector auxiliar para construir el IC. Nos va a decir que valores de
  #mu tomar para construir el IC
  #quiero que quede lleno de ceros
  for (j in 1:l){
    indica[j]=0
  }
  for(m in 1:l){#agarramos una mu y nos preguntamos si vive o no en el intervalo
    #de confianza
    Q<-0
    for(i in 1:n){
      Q=Q-2*log(pnorm((simulado[i]-inter[m])/2))
    }
    #print(Q)
    if((q1<Q) && (Q<q2)){
      indica[m]=1 #quiere decir que la m sí vive en el intervalo aleatorio
    }
    else{
      indica[m]=0 #entonces la m no esta en el intervalo de confianza
    }
  }
  u=which(indica==1) #nos ayuda a identificar que valores de m viven en el
  #intervalo aleatorio
  cotaInf[k]=inter[min(u)]
  cotaSup[k]=inter[max(u)]
}
cotaInf
cotaSup
#tambien podemos  contar cuantos intervalos de los 100 incluyen al valor de mu=2
cuentas=0
for(j in 1:100){
  if(cotaInf[j]<2 && 2<cotaSup[j]){
    cuentas<-cuentas+1
  }
}
print(cuentas)
#
#vamos a comparar con la otra cantidad pivotal
z=qnorm(0.975)
z
```

```
n<-10
cotIn1=1:100
cotSup1=1:100
for(k in 1:100){
  simula=rnorm(n,mean=2,sd=2)
  mediaMuestral=mean(simula)
  cotIn1[k]=mediaMuestral-(2*z)/sqrt(n)
  cotSup1[k]<-mediaMuestral+(2*z)/sqrt(n)
}
cotIn1
cotSup1
cuentas=0
for(i in 1:100){
  if(cotIn1[i]<2 && 2<cotSup1[i]){
    cuentas=cuentas+1
  }
}
print(cuentas)
#Nice
#ahora un tamano de muestra de n=100 para cada intervalo de confianza
n<-100
cotIn=1:100
cotSup=1:100
for(k in 1:100){
  simula=rnorm(n,mean=2,sd=2)
  mediaMuestral=mean(simula)
  cotIn[k]=mediaMuestral-(2*z)/sqrt(n)
  cotSup[k]<-mediaMuestral+(2*z)/sqrt(n)
}
cotIn
cotSup
cuentas=0
for(i in 1:100){
  if(cotIn[i]<2 && 2<cotSup[i]){
    cuentas=cuentas+1
  }
}
print(cuentas)
#listo.
#falta hacer analisis visual y analitico
#ya tenemos los intervalos que queremos. Falta interpretarlos y hacer observaciones
cotSup[1]-cotIn[1]
cotSup[2]-cotIn[2]
#siempre tienen la misma longitud estos intervalos pues su longitud no depende de
#la realizacion de la muestra (observada).
#primero comparemos las longitudes de los intervalos
```

```r
mean(cotaSup1-cotaInf1)
cotSup1[1]-cotIn1[1]
#por lo tanto, los intervalos de confianza construidos con la cantidad pivotal
#tienen longitud menor,
#y de acuerdo con ese criterio, son mejores.
#otro criterio es ver y comparar cuantos intervalos contienen al valor real que
#queremos estimar, osea mu=2
#si realizamos algunas simulaciones y corremos variaza veces el codigo, notamos que
#en general suele ser mejor cantidad pivotal
#Q2 que Q1, pues en general los intervalos de confianza constuidos con Q2 contienen
#al valor mu=2 en mas ocasiones
#
#ahora vamos a hacer plots de los intervalos de confianza
y=1:100
for(i in 1:100){
  y[i]=2 #es un vector lleno de dos para que ponga un puntito en el numero que queremos
  #estimar en el IC
}
#Q1, n=10
data1=data.frame(x=1:100,y=y, lower=cotaInf1, upper=cotaSup1)
data1
#existen dos modos de hacer el plot que queremos usando distintos paquetes de R
#haremos los dos
ggplot(data1, aes(x,y))+
  geom_point()+
  geom_errorbar(aes(ymin=lower, ymax=upper))
#Q2, n=10
data2=data.frame(x=1:100,y=y, lower=cotIn1, upper=cotSup1)
#usando el segundo metodo
plotCI(x=data2$x,y=data2$y,li=data2$lower,ui=data2$upper,) #usando plotrix
#Nice
#Q1, n=10
data1=data.frame(x=1:100,y=y, lower=cotaInf1, upper=cotaSup1)
data1
plotCI(x=data1$x,y=data1$y,li=data1$lower,ui=data1$upper,
       main=TeX('Intervalos de confianza obtenidos con $Q_{1}$ como cantidad pivotal,
                n=10 como tamaño de muestra para cada intervalo'), xlab='número de
                intervalo aleatorio simulado', ylab='intervalo')
#la desventaja de plotrix es que no es muy preciso al mostrar los intervalos
#de confianza que no contienen a mu=2
#por lo tanto conviene ggplot2, pero manejarlo con cuidado
#va con ggplot2
#Q1, n=10
data1=data.frame(x=1:100,y=y, lower=cotaInf1, upper=cotaSup1) #formamos un data frame
#con las cotas inferiores y superiores y queremos idemtificar mu=2
data1
```

```r
ggplot(data1, aes(x,y))+
  geom_point()+
  geom_errorbar(aes(ymin=lower, ymax=upper))+
  labs(title=TeX('Plot de intervalos de de confianza simulados a partir de $Q_1$ \n
                 con n=10 tamaño de muestra'), x='número de intervalo aleatorio
       observado', y='Intervalo aleatoio observado' )
#Q1, n=100
data2=data.frame(x=1:100,y=y, lower=cotaInf, upper=cotaSup)
data2
ggplot(data2, aes(x,y))+
  geom_point()+
  geom_errorbar(aes(ymin=lower, ymax=upper))+
  labs(title=TeX('Plot de intervalos de de confianza simulados a partir de $Q_{1}$
                 \n con n=100 tamaño de muestra'), x='número de intervalo aleatorio
       observado', y='Intervalo aleatoio observado' )
#Q2, n=10
data3=data.frame(x=1:100,y=y, lower=cotIn1, upper=cotSup1)
data3
ggplot(data3, aes(x,y))+
  geom_point()+
  geom_errorbar(aes(ymin=lower, ymax=upper))+
  labs(title=TeX('Plot de intervalos de de confianza simulados a partir de $Q_2$ \n con
                 n=10 tamaño de muestra'), x='número de intervalo aleatorio observado',
       y='Intervalo aleatoio observado' )
#Q2, n=100
data4=data.frame(x=1:100,y=y, lower=cotIn, upper=cotSup)
data4
ggplot(data4, aes(x,y))+
  geom_point()+
  geom_errorbar(aes(ymin=lower, ymax=upper))+
  labs(title=TeX('Plot de intervalos de de confianza simulados a partir de $Q_2$ \n con
                 n=100 tamaño de muestra'), x='número de intervalo aleatorio observado',
       y='Intervalo aleatoio observado' )
```